

Data Science Project

Présentation Générale

Verónica Peralta, Alexandre Chanson, Clément Legroux

2026

Plan

◆ Informations générales

- Objectifs, exemples de sujets, ressources humaines

◆ Organisation 2026-2027

- Calendrier et phases
- Encadrement
- Evaluation

◆ Description du sujet proposé

Objectifs généraux

◆ Faire une synthèse de vos connaissances acquises au travers d'un problème concret

- en préparation de données, entrepôts de données, fouille de données, statistiques...
- mais aussi en développement, gestion de projets, communication, anglais...

◆ Faire découvrir de nouveaux concepts

- Des techniques et technologies innovatrices
- Des domaines d'application spécialisés
- Des besoins applicatifs concrets

Sujets

- ◆ **Les sujets concernent la conception et le développement d'un système décisionnel permettant de :**
 - Modéliser et implémenter un entrepôt de données
 - Intégrer des données de différentes sources (bases de données, fichiers, données du web, documents, maps...)
 - Préparer ces données pour l'analyse
 - Concevoir des modèles de fouille de données
 - Effectuer des analyses approfondies de ces données
 - Interpréter des résultats et les restituer

Exemples de sujets précédents

2011	Traitement des statistiques d'usages des ressource électroniques, pour la Bibliothèque Universitaire
2012	Analyse d'indicateurs de développement durable, pour l'Observatoire de l'Economie et des Territoires du Loir-et-Cher
2013	Suivi des étudiants et analyse de la réussite, pour le Département d'Informatique de l'Université
2014	Analyse de la vulnérabilité énergétique des foyers du Loir et Cher, pour l'Observatoire de l'Economie et des Territoires du Loir-et-Cher
2015	
2016	Analyse des offres d'emplois dans le Loir et Cher, pour Neolink
2017	Analyse du parc végétal de l'agglomération de Grenoble, inspiré du défi EGC'2017
2018	Analyse d'événements d'erreur dans les équipements des trains, pour la SNCF
	Analyse de musique, sujet Open Source
2019	Surveillance de la tuberculose au Gabon – collaboration avec EDR infectiologie tropicale (Gabon)
	Analyse de patients atteints de SLA – collaboration avec le CHU de Tours
	Analyse de matches de Pokemon Showdown – sujet étudiant

Exemples de sujets précédents

2020	Evolution des niveaux des eaux souterraines – collaboration avec BRGM
	Archives du sol – collaboration avec LAT
2021	Raconter Rennes par la donnée – collaboration avec Rennes Métropole
2022	Analyse de décès impliquant la police aux USA – sujet Open Source
	Analyse de données immobilières – sujet étudiant
	Analyse de locations AirBNB – sujet étudiant
2023	Analyse de patients atteints de SLA – collaboration avec le CHU de Tours
	Evolution des décès liés à la consommation de drogues – sujet étudiant
	Analyse de tremblements de terre – sujet étudiant
2024	Impact des pratiques agricoles sur les écosystèmes sp. les insectes. – sujet Open Source
	Decoding Happiness – sujet étudiant
	Automated Image Processing of Galaxies for Cosmology – sujet étudiant
2025	Performance énergétique des logements français – sujet Open Source
	Plusieurs sujets étudiants (agriculture, obésité, professionnels de santé, climate trace)

Sujets 2026

◆ Tap Water Quality

- Données : fichiers en accès libre
- Besoins : identification des facteurs impactant la qualité de l'eau (agriculture, pesticides...)

◆ Possibilité de proposer un nouveau sujet

- Il faut fournir:
 - des sources de données
 - des besoins utilisateur
- Voir exemples sur Celene

Plus de details en fin de séance

Ressources humaines

◆ Travail en groupes de 3 ou 4 étudiants

- Veuillez à former des groupes hétérogènes, avec des compétences complémentaires (IT, modélisation, analyse, communication)
- Les groupes mixtes (FA + FI) ne sont pas possibles

◆ Un étudiant coordonnera chaque phase du projet

- Chargé de :
 - Planifier et suivre l'avancement du travail
 - Coordonner la division de travail et les moyens de communication
 - Organiser et animer les réunions internes
 - Veiller à la bonne communication entre les membres du groupe
 - Communiquer avec les enseignants en cas de difficultés ou questions
- Les coordinateurs changeront à chaque phase du projet. A chacun son tour !

Plan

- ◆ **Informations générales**

- Objectifs, exemples de sujets, ressources humaines

- ◆ **Organisation 2026-2027**

- Calendrier et phases
- Encadrement
- Evaluation

- ◆ **Description du sujet proposé**

Calendrier

◆ Projet se déroulant sur 2 semestres:

- sept-dec : Développement d'un entrepôt
- janv-avr : Fouille de données

◆ Calendrier du 1^{er} semestre →

◆ Cette fin de semaine :

- Formation des groupes
- Recherche de données et besoins

Date		Project phases		
1	1/9	study (2 weeks)		
	1/9			
	3/9			
2	8/9			
	10/9			
3	15/9	modeling (3 weeks)		
	17/9			
4	22/9			
	24/9			
5	29/9			
6	6/10	loading (4 weeks)		
7	13/10			
8	20/10			
	27/10			
9	3/11			
10	10/11	reporting (3 5 weeks)		
11	17/11			
12	24/11			
EX	1/12			
13	8/12			
14	15/12			

Phases du projet

1. Study (2 semaines)

- Choix du sujet, compréhension du sujet
- Extraction des données, compréhension des données
- Spécification de la charge de travail préliminaire (workload)

2. Modeling (3 semaines)

- Conception conceptuelle de l'entrepôt, formalisation de la charge de travail

3. Loading (3+4 semaines)

- Définition de l'architecture de l'entrepôt
- Profilage et étude statistique des données
- Transformation et nettoyage de données
- Charge des données avec des outils ETL

4. Reporting (3 semaines en FA, 5 semaines en FI)

- Restitution avec des outils variés afin d'illustrer la réponse aux besoins

Encadrement

◆ Equipe enseignant :

Verónika Peralta, Alexandre Chanson, Clément Legroux
prenom.nom@univ-tours.fr



◆ Interactions :

- Cours en ligne sur Celene
 - <http://celene.univ-tours.fr/course/view.php?id=18642>
 - Clé d'inscription : M1-PROJ
- Séances de questions et de suivi
- Séances notées de fin de phase
- Soutenances de fin de semestre

Planning préliminaire

Date		Project phases	Deliverable	Classes	
				Supervision	Grading
1	1/9	study (2 weeks)		presentation	
	1/9			data analysis lab	
	3/9			questions	
2	8/9			questions	
	10/9		report		
3	15/9	modeling (3 weeks)			q&a
	17/9			questions	
4	22/9			questions	
	24/9			questions	
5	29/9		report		
6	6/10	loading (4 weeks)			q&a
7	13/10			questions	
8	20/10			questions	
	27/10				
9	3/11			questions	
10	10/11	reporting (3 5 weeks)			demo
11	17/11			questions	
12	24/11		report+slides (A)	questions (A)	
EX	1/12				defense (A)
13	8/12		report+slides (I,N)	questions (I,N)	
14	15/12				defense (I)

Travail identique pour tous les groupes

Les groupes FA implémentent une partie de l'entrepôt

Les groupes FI implémentent tout l'entrepôt

Séances de questions

- ◆ **Objectif :** Montrer l'avancement, poser des questions et demander des précisions sur le sujet ou sur des tâches spécifiques
- ◆ **Déroulement :**
 - L'encadrant sera disponible, en salle machine, pour des questions, que ça soit en groupe ou en plénière.
- ◆ **Pour préparer la réunion :**
 - Chaque groupe amènera tous les documents nécessaires (tables, diagrammes, maquettes, prototypes...) afin de montrer son avancement dans la phase.
 - Des documents additionnels peuvent être demandés à un groupe (en fonction de sa performance dans les réunions précédentes)
 - Des démos peuvent être demandées.
- ◆ **Durée:**
 - Séances de 4h à répartir entre les groupes (malgré le découpage dans vos EDT)
 - Vous pouvez travailler sur place dans l'intégralité de la séance

Séances notés : rapport + q&a

- ◆ **Objectif : Montrer la conduite et les résultats de la phase**
 - Rappeler le problème posé et les résultats précédents
 - Présenter les choix effectués, les solutions proposées, les limites
 - Présenter les résultats les plus importants de chaque tâche
 - Indiquer l'organisation et le suivi du projet
 - Indiquer les difficultés rencontrées et valoriser les leçons apprises.
- ◆ **Chaque groupe sera noté sur ses résultats**
 - Livrables rendus via Celene les vendredis avant 18h
 - Certaines séances demandent une démo
 - Veillez à lancer vos outils à l'avance pour optimiser votre temps
 - Les résultats sont discutés et peuvent être māj pour la soutenance
- ◆ **Durée: 20 minutes par groupe**

Soutenance

♦ La fin du semestre sera évaluée par :

- Le système livré
- La remise d'un rapport (maximum 20 pages) et des supports de présentation
 - Rendus via Celene le vendredi précédant la soutenance, avant midi
- Une présentation orale et une démo du prototype (15 minutes)
 - Une répétition pourra être animée par l'enseignant d'anglais (au 2^e semestre)
- Des questions du jury (15 minutes)

♦ Objectif : Résumer le projet

- Résumer le problème posé, l'organisation, les choix effectués, les problèmes rencontrés et solutions proposées, les perspectives possibles.
- Faire une analyse interactive des données afin d'illustrer la réponse aux besoins
- Inclure en annexe un manuel d'installation et d'utilisation du système, ainsi que la documentation technique (mise à jour si nécessaire).

Evaluation

◆ Vous serez notés sur :

- Vos réalisations dans chaque phase (évaluées lors des séances notées)
- Les supports rendus (documents, vidéos, slides, prototype)
- Votre expression orale et vos réponses aux questions

◆ Il y aura des notes groupales et individuelles

- Inclura une évaluation par les pairs

◆ Une moyenne sera calculée chaque semestre

◆ Il n'y a pas de deuxième session (la note est conservée)

Evaluation

◆ Barème de notation

Calculation of phase grades		Phases			
		Study	Modeling	Loading	Reporting
Software products	Report, apendix	14	14	6	4
	Demo, vidéo			8	4
	Prototype				4
Communication	Presentation				4
	Questions and answers	6	6	6	4
		20	20	20	20
Weights for calculation of semester grades		0.10	0.30	0.30	0.30

D'autres précisions

◆ Langages

- Certains rapports et documents techniques seront rédigés en anglais.
- L'interface utilisateur et les manuels peuvent être en anglais ou français (dépend du sujet).
- Les bases de données, code et commentaires seront dans la même langue que les données (dépend du sujet).

◆ Outils informatiques

- Une machine virtuelle, hébergée sur notre serveur DELL R820, pourra vous être fournie (au choix, Windows ou Linux)
- Chaque groupe installera, évaluera et choisira ses outils
 - Certains sujets peuvent contraindre les outils à utiliser

D'autres précisions

◆ Facilité d'installation et d'usage :

- Installation guidée et simple.
- Interfaces très simples à utiliser (notamment par des utilisateurs non informaticiens).
- La documentation doit être facile à utiliser.

◆ Extensibilité

- Des nouveaux besoins et/ou données sources vont apparaître en cours de projet.
 - Des nouvelles variables doivent s'ajouter sans trop d'effort (sans tout refaire)
- La documentation doit permettre une maintenance facile.

Pour la séance prochaine

◆ Compréhension des sujets

- Chaque étudiant.e lit le sujet proposé et des anciens sujets en exemple, cherche des idées et se positionne

◆ Formation des groupes

- Par affinité, complémentarité et/ou préférence de sujet
- Chaque groupe choisi/personnalise un sujet selon ses critères
 - Indépendamment du choix des autres groupes
- Chaque groupe désigne les coordinateurs des phases

◆ Séance de questions : voir EDT

Plan

- ◆ **Informations générales**

- Objectifs, exemples de sujets, ressources humaines

- ◆ **Organisation 2025-2026**

- Calendrier et phases
- Encadrement
- Evaluation

- ◆ **Description du sujet proposé**