

Questions-réponses pour la soutenance

Projet Qualité de l'eau du robinet et pression agricole

1. Questions sur le contexte et le sujet

Q : Pourquoi ce sujet est important ?

R : L'eau du robinet c'est un enjeu de santé publique direct. En France, plus de 300 000 prélèvements sont faits chaque année pour vérifier la qualité de l'eau. Et en parallèle, l'agriculture utilise massivement des pesticides qui finissent par s'infiltrer dans les nappes phréatiques. La question est simple : est-ce que là où on traite le plus avec des pesticides, on retrouve une eau de moins bonne qualité ? C'est ça qu'on veut vérifier.

Q : C'est quoi la Directive 98/83/CE ?

R : C'est la directive européenne qui fixe les normes de qualité pour l'eau potable. Elle définit les seuils à ne pas dépasser pour chaque paramètre (pesticides, nitrates, bactéries, etc.). Quand on parle de conformité ou non-conformité dans notre projet, c'est par rapport à ces seuils-là.

Q : Quelle est votre question centrale ?

R : La pression agricole se traduit-elle par une dégradation mesurable de la qualité de l'eau du robinet ? En d'autres termes, est-ce que les départements qui utilisent le plus de pesticides ont aussi plus de prélèvements d'eau non conformes.

Q : Pourquoi vous avez choisi 4 axes ?

R : Parce qu'on est 4 dans le groupe et la consigne demande 2 questions par personne. Mais au-delà de ça, les 4 axes se complètent : d'abord on regarde où ça ne va pas (axe 1 - cartographie), ensuite on cherche pourquoi (axe 2 - corrélation avec les pesticides), puis on regarde si ça évolue dans le temps (axe 3), et enfin on essaie de prédire quelles communes sont à risque (axe 4). C'est une progression logique.

2. Questions sur les données

Q : D'où viennent vos données ?

R : On a deux sources principales. La première c'est SISE-Eaux, la base du ministère de la Santé. Elle contient les résultats de tous les contrôles sanitaires de l'eau du robinet en France, commune par commune. La deuxième c'est Solagro, un organisme qui a cartographié l'usage des pesticides en agriculture pour 2020, 2021 et 2022. Les deux sources sont fournies dans la consigne du projet.

Q : C'est quoi la différence entre DIS_PLV et DIS_RESULT ?

R : DIS_PLV c'est le fichier des prélèvements. Chaque ligne représente un prélèvement fait dans une commune, avec un verdict global : conforme ou non conforme, chimiquement et bactériologiquement. C'est un résumé. DIS_RESULT c'est le détail : chaque ligne représente la mesure d'un paramètre précis, avec sa valeur et le seuil réglementaire. Il est beaucoup plus gros, on dépasse le million de lignes par an.

Q : C'est quoi les valeurs C, N, S et D dans DIS_PLV ?

R : C veut dire conforme, le prélèvement respecte tous les seuils. N veut dire non conforme, au moins un paramètre dépasse la limite. S veut dire sans objet, le paramètre n'a pas été testé. D veut dire dérogation, il y a un dépassement mais une dérogation a été accordée.

Q : C'est quoi l'IFT ?

R : L'Indice de Fréquence de Traitement. C'est le nombre moyen de traitements phytosanitaires appliqués par hectare sur une campagne agricole. Si l'IFT vaut 3, ça veut dire qu'en moyenne chaque hectare a reçu 3 doses

de produit. Plus c'est élevé, plus la pression pesticide est forte. Dans les données Solagro, on a l'IFT total (ift_t), l'IFT herbicides (ift_h) et l'IFT hors herbicides (ift_t_hh).

Q : Comment vous faites la jointure entre les données d'eau et les données pesticides ?

R : On passe par le code département. Dans DIS_PLV, le département est dans la première colonne (cddept). Dans Solagro, on a le code commune INSEE à 5 chiffres, et les deux premiers chiffres donnent le département. Le problème c'est que dans les fichiers d'eau, certains codes sont notés sans le zéro devant (1 au lieu de 01). Il faut harmoniser ça au moment du nettoyage.

Q : Le fichier DIS_RESULT est trop gros pour Excel, comment vous faites ?

R : On utilise RStudio et KNIME. RStudio peut lire des fichiers CSV de n'importe quelle taille avec la fonction read.csv() ou fread() du package data.table. KNIME peut aussi charger des fichiers volumineux dans ses workflows. Excel est limité à un peu plus d'un million de lignes, donc pour DIS_RESULT on ne passe pas par Excel.

Q : Vous avez déjà regardé les données ?

R : Oui, on a fait un premier audit sur les fichiers de 2016. On a identifié la structure des colonnes, les valeurs possibles pour la conformité, le nombre de paramètres dans DIS_RESULT, et le format des codes communes. On a aussi repéré les problèmes potentiels : codes INSEE sans zéro devant, fichier RESULT très volumineux, données non nettoyées.

Q : Pourquoi la période 2020-2022 ?

R : Parce que c'est la seule période où on a les deux sources en même temps. Solagro couvre 2020, 2021 et 2022. Les données d'eau vont de 2016 à 2025, mais pour croiser les deux il faut qu'elles couvrent les mêmes années. Cela dit, pour l'axe 3 (évolution temporelle), on pourra utiliser les données d'eau sur une période plus large pour voir des tendances longues.

3. Questions sur les méthodes

Q : C'est quoi la différence entre data analyse et data science dans votre projet ?

R : La data analyse c'est la partie descriptive : on explore les données, on fait des graphiques, on calcule des taux, on regarde les distributions. C'est pour comprendre ce qu'on a sous les yeux. La data science c'est la partie où on utilise des méthodes statistiques ou du machine learning pour aller plus loin : tester si une corrélation est significative, construire un modèle de prédiction, regrouper des communes en profils. La data analyse répond à « qu'est-ce qu'on voit ? », la data science répond à « est-ce que c'est significatif ? ».

Q : Pourquoi Spearman et pas Pearson ?

R : Pearson suppose que les deux variables suivent une distribution normale, c'est-à-dire une courbe en cloche bien régulière. Nos données ne sont probablement pas comme ça : les taux de non-conformité sont sans doute très concentrés autour de valeurs basses avec quelques départements bien au-dessus. Spearman travaille sur les rangs, pas sur les valeurs brutes, donc il n'a pas besoin de cette hypothèse. C'est plus robuste pour nos données.

Q : C'est quoi un test de Shapiro-Wilk et pourquoi vous le faites ?

R : C'est un test qui vérifie si un ensemble de valeurs suit une distribution normale. On le fait en premier dans l'axe 1 parce que le résultat nous guide pour la suite. Si la distribution est normale, on peut utiliser Pearson. Si elle ne l'est pas, on utilise Spearman et Mann-Whitney. C'est une étape de diagnostic, pas un résultat en soi.

Q : C'est quoi le test de Mann-Whitney ?

R : C'est un test qui compare deux groupes pour voir si leurs distributions sont différentes. Dans notre cas, on compare les taux de non-conformité de 2020 avec ceux de 2022, département par département. Le test nous dit si la différence qu'on observe visuellement est statistiquement significative, ou si ça pourrait être juste du bruit.

Q : C'est quoi la p-value ?

R : C'est la probabilité d'obtenir le résultat qu'on observe par pur hasard. Si la p-value est inférieure à 0,05, ça veut dire qu'il y a moins de 5 % de chances que ce soit du hasard. On considère alors que le résultat est statistiquement significatif. C'est le seuil standard utilisé en sciences.

Q : C'est quoi une régression linéaire simple ?

R : C'est un modèle qui cherche la droite qui passe le mieux à travers un nuage de points. On a une variable explicative (la variation de l'IFT) et une variable à expliquer (la variation de la conformité). Le R^2 nous dit quelle part de la variation est expliquée par le modèle. Si $R^2 = 0,7$, ça veut dire que 70 % de ce qui se passe dans la conformité est lié à ce qui se passe dans l'IFT.

Q : C'est quoi le clustering K-means ?

R : C'est un algorithme qui regroupe automatiquement des observations en K groupes selon leur ressemblance. Chaque commune est décrite par plusieurs chiffres (IFT, SAU, population, taux de non-conformité), et K-means regarde lesquelles se ressemblent le plus pour les mettre dans le même groupe. On choisit le bon nombre de groupes avec la méthode du coude : on teste K=2, 3, 4, 5... et on regarde à partir de quel K ça n'améliore plus beaucoup.

Q : C'est quoi la méthode du coude ?

R : Quand on fait du K-means, on doit choisir combien de groupes on veut. La méthode du coude consiste à tracer un graphique avec le nombre de groupes en X et la qualité du regroupement en Y. Au début, ajouter un groupe améliore beaucoup le résultat. A un moment, ça n'améliore presque plus. Le point où la courbe fait un « coude » c'est le bon nombre de groupes.

Q : C'est quoi la régression logistique ?

R : C'est un modèle de classification, pas de régression malgré son nom. Il prédit une probabilité entre 0 et 1. Dans notre cas, il prédit la probabilité qu'une commune soit « à risque » en fonction de ses caractéristiques agricoles. Si le modèle dit 0,85 pour une commune, ça veut dire qu'il estime qu'elle a 85 % de chances d'avoir de l'eau non conforme.

Q : C'est quoi la validation croisée ?

R : C'est une technique pour évaluer un modèle sans tricher. On coupe les données en 5 morceaux. On entraîne le modèle sur 4 morceaux et on le teste sur le 5e. On répète ça 5 fois en changeant le morceau de test à chaque fois. La performance finale c'est la moyenne des 5 résultats. Ça empêche le modèle de simplement « mémoriser » les données au lieu de les comprendre.

Q : C'est quoi la matrice de confusion ?

R : C'est un tableau 2x2 qui montre les résultats du modèle. En lignes, la réalité (commune vraiment à risque ou vraiment conforme). En colonnes, ce que le modèle a prédit. Ça donne 4 cases : vrais positifs (bien prédit à risque), vrais négatifs (bien prédit conforme), faux positifs (le modèle dit à risque alors que c'est conforme) et faux négatifs (le modèle dit conforme alors que c'est à risque).

Q : C'est quoi la courbe ROC et l'AUC ?

R : La courbe ROC montre comment le modèle performe à différents seuils de décision. L'AUC c'est l'aire sous cette courbe, résumée en un seul chiffre entre 0 et 1. Si l'AUC vaut 0,5, le modèle ne fait pas mieux que le hasard. Si elle vaut 0,8, c'est un bon modèle. 1,0 serait un modèle parfait, ce qui n'arrive jamais en pratique.

Q : C'est quoi l'analyse de Pareto ?

R : C'est le principe du 80/20. On trie les paramètres du plus fréquemment dépassé au moins fréquemment dépassé, et on regarde lesquels représentent 80 % des non-conformités totales. L'idée c'est que souvent un petit nombre de paramètres est responsable de la majorité des problèmes. Ça nous permet de cibler notre analyse.

4. Questions sur les outils

Q : Pourquoi ces outils et pas d'autres ?

R : Ce sont les outils qu'on a à disposition dans la formation. Excel pour le nettoyage de base, Tableau pour les visuels, KNIME pour le machine learning sans coder, RStudio pour les tests statistiques. On n'a pas choisi des outils compliqués pour impressionner, on a pris ce qu'on sait utiliser.

Q : Pourquoi KNIME et pas Python pour le machine learning ?

R : KNIME est plus accessible pour un travail de groupe. On construit le pipeline visuellement en connectant des blocs, tout le monde peut comprendre et modifier le workflow. Avec Python, il faut que tout le monde sache coder, ce qui n'est pas forcément le cas de chaque membre du groupe au même niveau.

Q : Pourquoi RStudio pour les tests statistiques ?

R : R est fait pour la statistique. Les tests comme Spearman, Mann-Whitney et la régression sont natifs dans R, pas besoin d'installer quoi que ce soit. En plus, R gère sans problème les fichiers volumineux comme DIS_RESULT qui dépassent la limite d'Excel.

Q : Comment vous allez partager le travail concrètement ?

R : Chacun a son axe et ses 2 questions. Le nettoyage et l'harmonisation des codes INSEE on le fait ensemble au début, parce que tout le monde en a besoin. Ensuite chacun travaille sur ses questions. Les résultats de l'axe 1 (les taux de non-conformité par département) servent de base aux axes 2 et 3, donc Sham commence en premier.

5. Questions pièges et limites

Q : Est-ce que corrélation veut dire causalité ?

R : Non. Même si on trouve une corrélation forte entre l'IFT et la non-conformité, ça ne prouve pas que les pesticides causent directement la non-conformité. Il peut y avoir d'autres facteurs : le type de sol, la profondeur des nappes, le réseau de distribution, etc. On dit qu'il y a un lien statistique, pas une relation de cause à effet. C'est une limite connue de notre approche.

Q : Avec seulement 2-3 années de données Solagro, est-ce suffisant ?

R : C'est une limite réelle. 3 ans c'est court pour voir des tendances. Mais c'est ce qu'on a, et la consigne est basée là-dessus. Ce qu'on peut faire c'est être honnête dans nos conclusions et ne pas généraliser au-delà de ce que les données permettent.

Q : Vos données sont propres ?

R : Non, elles ne sont pas nettoyées. On s'attend à des valeurs manquantes, des doublons, des codes mal renseignés. Le nettoyage fait partie du travail et on l'a prévu comme première étape. On ne pourra mesurer l'ampleur des problèmes qu'en ouvrant les fichiers complets.

Q : Le département c'est pas trop grossier comme granularité ?

R : C'est un compromis. La commune serait plus précise mais les jointures seraient plus compliquées et les effectifs par commune parfois trop faibles pour être significatifs. Le département permet d'avoir assez de prélèvements pour calculer des taux fiables. Et dans l'axe 4, on descend justement à la commune pour le clustering et la prédiction.

Q : Qu'est-ce qui se passe si vous ne trouvez pas de corrélation ?

R : Ça reste un résultat valable. Si on ne trouve pas de lien entre l'IFT et la non-conformité, ça veut dire que d'autres facteurs sont en jeu (géologie, réseau de distribution, type de traitement de l'eau...). Le but c'est de répondre à la question honnêtement, pas de trouver un résultat qui nous arrange.

Q : Pourquoi vous n'avez pas utilisé les données anglaises (DEFRA) ?

R : C'est une piste optionnelle mentionnée dans la consigne. On a préféré se concentrer sur les données françaises pour bien faire le travail de base plutôt que de s'éparpiller. Si on a le temps en fin de projet, on pourra ajouter une comparaison, mais ce n'est pas prioritaire.

Q : Qu'est-ce que vous feriez si vous aviez plus de temps ?

R : Trois choses. D'abord, inclure plus de variables explicatives dans le modèle de prédiction : type de sol, densité du réseau hydrographique, type de traitement de l'eau. Ensuite, étendre la période d'analyse pour voir des tendances plus longues. Enfin, descendre à la commune pour tous les axes, pas seulement l'axe 4.

6. Questions spécifiques par axe

Q : [Axe 1] Comment vous calculez le taux de non-conformité ?

R : C'est simple : nombre de prélèvements avec la valeur N (non conforme) dans le champ plvconformitechimique, divisé par le nombre total de prélèvements dans ce département, multiplié par 100 pour avoir un pourcentage. On fait le même calcul pour la conformité bactériologique.

Q : [Axe 1] C'est quoi une carte choroplèthe ?

R : C'est une carte où chaque zone (ici chaque département) est colorée selon une valeur. Plus la couleur est foncée, plus le taux est élevé. On la fait dans Tableau, il gère ça nativement avec les codes départements français.

Q : [Axe 2] Pourquoi vous comparez aussi herbicides vs insecticides séparément ?

R : Parce que les pesticides ne sont pas tous les mêmes. Les herbicides, les insecticides et les fongicides n'ont pas les mêmes propriétés chimiques et ne se comportent pas pareil dans le sol et les nappes. Savoir lequel est le plus corrélé aux non-conformités, ça permet de cibler les recommandations.

Q : [Axe 3] Pourquoi Mann-Whitney et pas un t-test ?

R : Le t-test suppose que les données suivent une loi normale. Mann-Whitney ne fait pas cette hypothèse. Comme nos taux de non-conformité ne sont probablement pas distribués normalement (beaucoup de valeurs basses, quelques-unes très élevées), Mann-Whitney est plus adapté.

Q : [Axe 4] Comment vous définissez une commune « à risque » ?

R : On prend un critère simple : si la commune a eu au moins un prélèvement non conforme sur la période étudiée, elle est classée « à risque ». Sinon elle est « conforme ». C'est binaire, c'est ce qui permet de faire la régression logistique.

Q : [Axe 4] Le K-means et la régression logistique, c'est pas la même chose ?

R : Non, ce sont deux choses différentes. Le K-means regroupe les communes en profils sans savoir à l'avance lesquels sont à risque - c'est de l'apprentissage non supervisé. La régression logistique utilise les données

étiquetées (à risque ou pas) pour apprendre à prédire - c'est de l'apprentissage supervisé. Les deux se complètent : K-means pour comprendre les profils, régression logistique pour prédire.